

TP 1: Map Reduce

Exercice 1 :

1- On souhaite développer un Job Map Reduce permettant, à partir d'un fichier texte (ventes.txt) en entrée, contenant les ventes d'une entreprise dans les différentes villes, de déterminer le total des ventes par ville. La structure du fichier ventes.txt est de la forme suivante :

date ville produit prix

Vous testez votre code en lançant le job sur le cluster Hadoop.

2- Vous créez un deuxième job permettant de calculer le prix total des ventes des produits par ville pour une année donnée.

Exercice 2 :

On dispose d'un grand ensemble de fichiers journaux (logs) Web générés par un serveur. Chaque ligne du fichier journal contient des informations sur les requêtes HTTP, y compris l'adresse IP du client, la date, le chemin d'accès demandé, le code de réponse HTTP, etc. L'objectif est d'effectuer une analyse des logs pour trouver le nombre total de requêtes par adresse IP, ainsi que le nombre de requêtes réussies (code de réponse HTTP 200) par adresse IP.

Données d'entrée : Un ensemble de fichiers journaux Web au format texte. Par exemple :

```
192.168.1.1 - - [12/May/2023:15:30:45 +0000] "GET /page1 HTTP/1.1" 200 1234
192.168.1.2 - - [12/May/2023:15:31:02 +0000] "GET /page2 HTTP/1.1" 404 567
192.168.1.1 - - [12/May/2023:15:32:10 +0000] "GET /page1 HTTP/1.1" 200 789
192.168.1.3 - - [12/May/2023:15:32:35 +0000] "GET /page3 HTTP/1.1" 200 987
```

Travail à faire : Utilisez Hadoop MapReduce pour calculer le nombre total de requêtes et le nombre de requêtes réussies (code de réponse 200) par adresse IP.